

<https://github.com/Souha-dev/bigdataLabs.git>

1) Créer des sections pour chaque partie :

- SECTION 1 : Installation & imports
- SECTION 2 : Serveur socket (source de données)
- SECTION 3 : SparkContext + StreamingContext
- SECTION 4 : Création du DStream (socketTextStream)
- SECTION 5 : Traitement WordCount (split, map, reduceByKey)
- SECTION 6 : Affichage + démarrage + arrêt du streaming

2) Chaque section doit être commentée :

☑ J'ai ajouté des commentaires explicatifs.

3) Modifier le code afin que la lecture aléatoire soit faite depuis un fichier

J'ai ajouté un fichier nommé (messages.txt), et aussi ajouté serveur socket lit le fichier et envoie une ligne aléatoire

4) Qu'est-ce qu'un micro-batch dans DStream ?

Un micro-batch est un petit lot de données collectées pendant un intervalle de temps, puis traité comme un job Spark.

5) Sur quelle structure repose un DStream ?

Un DStream repose sur une suite de RDD (un RDD par micro-batch).

6) Quelle est la durée du batch utilisée ?

la durée du batch utilisée c'est 5 seconds (ssc = StreamingContext(sc, 5))